PONTIFÍCIA UNIVERSIDADE CATÓLICA DE CAMPINAS

ISABEL BAUNGARTNER - RA: 25001436

JULIA DE SOUZA LEANDRO - RA: 25009148

LAVÍNIA OLIVEIRA DOS SANTOS - RA: 25894981

MARIA EDUARDA FONSECA - RA: 25015976

RELATÓRIO DE PROJETO:

Imputação de Dados

CAMPINAS

2025

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE CAMPINAS
ESCOLA POLITÉCNICA,
Ciências de Dados e Inteligência Artificial

RELATÓRIO DE PROJETO:
Imputação de Dados

Relatório de projeto de sistema, apresentado no componente curricular Mineração de Dados e Visualização, do curso de Ciências de Dados e Inteligência Artificial, da Escola Politécnica da Pontifícia Universidade Católica de Campinas.

Orientador: Felipe Cavalaro

CAMPINAS
2025

SUMÁRIO

1. Introdução 4
2. Requisitos 4
3. Dashboard com os Dados da Base Original 5
3.1. Massa Corporal Média e Tamanho Médio da Asa – Antes 5
3.2. Comprimento Médio do Bico e Profundidade Média do Bico – Antes 6
4. Imputação de Colunas Numéricas 6
4.1. Justificativa da Escolha do Método de Imputação: KNN Imputer 7
4.2. Pré-processamento: Normalização com MinMaxScaler 7
4.3. Avaliação da Imputação e Distribuição Estatística 8
4.4. Código de Imputação Utilizado nas Colunas Numéricas 10
5. Imputação de Colunas Categóricas 12
5.1. Justificativa do Método FFILL – Colunas Species e Island 13
5.2. Código de Imputação Utilizado – Species e Island 14
5.3. Justificativa Método por Característica – Coluna Sex 15
5.4. Código de Imputação Utilizado – Sex 16
6. Dashboard com os Dados da Base Imputada 18
6.1. Massa Corporal Média e Tamanho da Asa – Depois 18
6.2. Comprimento e Profundidade do Bico – Depois 19
7. Conclusão 20

1. Introdução

O projeto teve como objetivo tratar a base de dados Palmer Penguins, que estava com 30% dos dados ausentes. Usamos Python e bibliotecas como pandas, numpy, seaborn e scikit-learn para aplicar as técnicas de imputação e visualizar os resultados antes e depois do tratamento. As estratégias de imputação incluíram o uso de K-Nearest Neighbors (KNN), o método Forward Fill (ffill) e também a imputação baseada em características reais dos pinguins, como a espécie e o tamanho do bico, respeitando os padrões biológicos presentes na base

2. Requisitos

Requisitos avaliados definidos pelo professor Felipe Cavalaro são:

1. A base original (com valores ausentes) não deve ser alterada diretamente, e não deve ser utilizada a base completa sem NaNs para buscar os valores corretos.
2. Devem ser utilizados os dados com valores faltantes (NaNs), e o objetivo é realizar a correção (imputação) da base para permitir seu uso posterior em algoritmos de aprendizado de máquina e mineração de dados.
3. A distribuição dos dados antes e depois da imputação deve ser comparada visualmente por meio de dashboards desenvolvidos no Power BI.
4. A imputação das colunas numéricas deve ser realizada utilizando técnicas justificadas com base na análise exploratória, podendo incluir normalização, análise de similaridade, entre outros.
5. A imputação das colunas categóricas deve considerar relações contextuais entre as variáveis (ex: espécies e ilhas), evitando o uso ingênuo da moda quando isso puder distorcer os dados.
6. Cada etapa de imputação deve ser documentada em um notebook Python, com os códigos executados e suas respectivas justificativas bem escritas.
7. As justificativas são os elementos mais importantes da avaliação, sendo atribuído maior peso às explicações e escolhas feitas do que à técnica usada em si.
8. O trabalho deve ser feito em grupo com até 4 alunos, e a nota será atribuída após arguição oral em aula.
9. A entrega deve ser feita via Canvas, e há penalidade de 1 ponto por dia de atraso.

3. Dashboard com os Dados da Base Original

Para entender o impacto da ausência de dados e justificar os meios de imputação, foram criados dashboards em Power BI a partir da base com valores NANs. Os dashboards analisam métricas descritivas como média de massa corporal, dimensão da asa, extensão e profundidade do bico, divididos por espécie, gênero e ilha.

3.1. Massa Corporal Média e Tamanho Médio da Asa – Antes

Os gráficos estão organizados por ilha, gênero e espécie, possibilitando uma análise segmentada dos dados. A existência de categorias como "Ilha: Desconhecida*" e "Sexo: em branco" evidencia a quantidade de valores ausentes em colunas categóricas cruciais como island e sex.

A grande quantidade de registros em categorias "em branco" indica que a falta de dados não é dispersa: existe um padrão relevante de falta de informação que compromete várias variáveis.

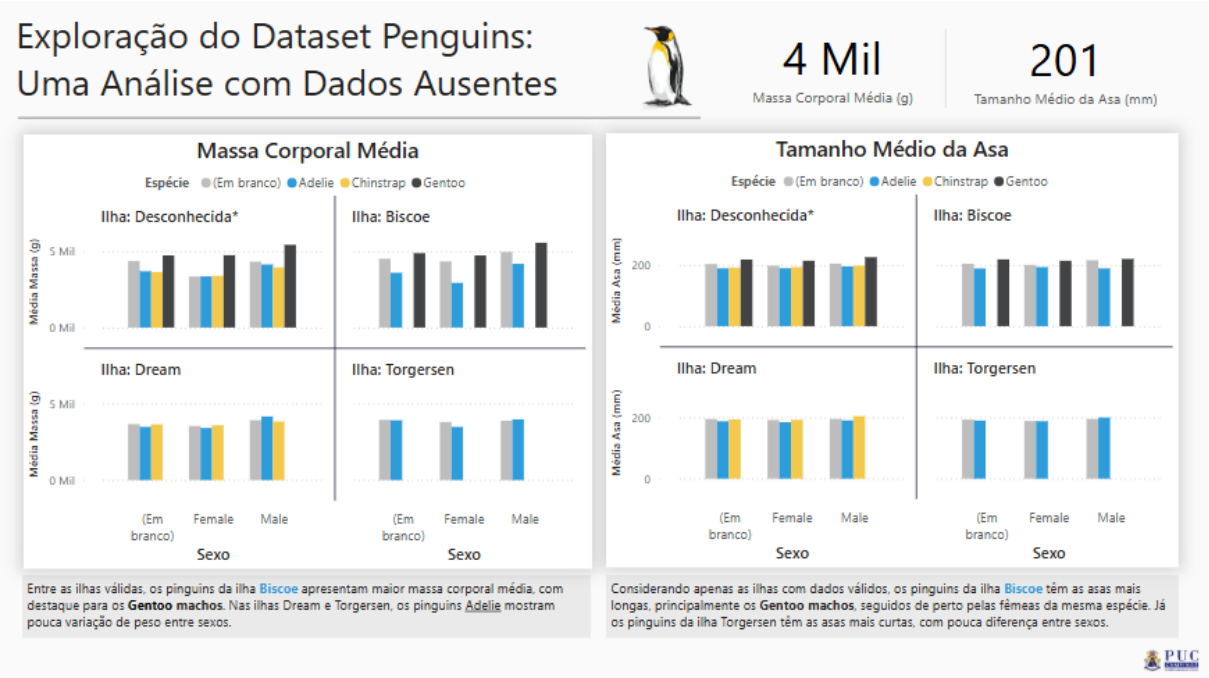

Figura 01 – Dashboard de Massa Corporal Média e Tamanho da Asa Antes da Imputação

3.2. Comprimento Médio do Bico e Profundidade Média do Bico – Antes

Os diagramas de bill_length_mm e bill_depth_mm mostram o impacto negativo dos valores ausentes em colunas numéricas.

Registros com dados ausentes, como sexo e ilha em branco, aparecem nos gráficos como categorias separadas. Isso ajuda a visualizar facilmente onde a base original estava incompleta.

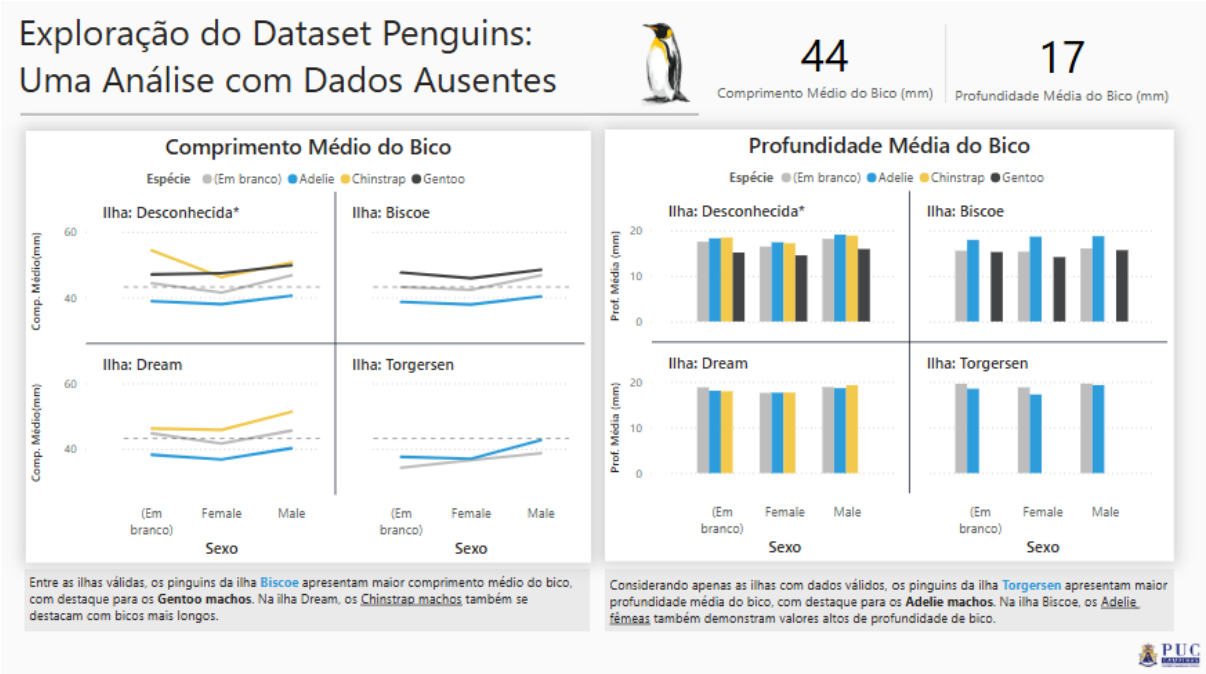

Figura 02 – Comprimento Médio do Bico e Profundidade Média do Bico Antes da Imputação

4. Imputação de Colunas Numéricas

As colunas numéricas do dataset “bill_length_mm”, “bill_depth_mm”, “flipper_length_mm” e “body_mass_g” são fundamentais para a análise das características morfológicas dos pinguins. Antes de aplicar qualquer técnica de imputação, é essencial entender sobre o que cada uma delas se trata:

- **bill_length_mm:** Comprimento do bico em milímetros, usado para diferenciar espécies e sexos, já que está relacionado à dieta e ao habitat dos pinguins.
- **bill_depth_mm:** Profundidade do bico em milímetros, também usada na diferenciação entre espécies e no reconhecimento de dimorfismo sexual.
- **flipper_length_mm:** Comprimento da nadadeira em milímetros, ligado à capacidade de nado e adaptação aquática dos pinguins.

- **body_mass_g:** Massa corporal em gramas, indica o peso do pinguim e pode refletir saúde, estágio reprodutivo e reservas energéticas.

Essas variáveis apresentam valores ausentes em proporções consideráveis na base alterada usada neste projeto. A ausência dessas informações prejudica diretamente a análise estatística e visual dos dados, afetando tanto a média quanto a variabilidade.

4.1. Justificativa da Escolha do Método de Imputação: KNN Imputer

Para a imputação dos dados faltantes nas colunas numéricas, utilizamos o KNN Imputer (K-Nearest Neighbors), uma técnica que se mostrou mais eficaz do que métodos tradicionais como a média ou a mediana. Ao contrário da média, que considera todos os registros e pode ser fortemente influenciada por outliers ou dados atípicos, o KNN se baseia apenas nos registros mais semelhantes ao que possui o valor ausente. Isso torna o preenchimento dos dados mais preciso e contextualizado, pois considera o perfil dos dados ao redor (ou seja, seus "vizinhos").

Enquanto a média gera um único valor genérico, o KNN analisa as distâncias entre os registros (após normalização dos dados) e busca os K mais próximos, neste caso, K = 5. Escolhemos 5 pois se o valor de K for muito pequeno (por exemplo, 2 ou 3), o modelo pode ficar muito sensível a ruídos, o que prejudica a imputação e se for muito grande, o algoritmo pode considerar registros muito diferentes do ponto com valor ausente, diluindo a similaridade e tornando o preenchimento menos representativo. Com K = 5, conseguimos utilizar um padrão confiável e coerente com o contexto local, garantindo uma imputação mais precisa e alinhada com a estrutura real dos dados.

E também colocamos o parâmetro “weights = 'distance'”, pois ele dá mais peso aos registros mais próximos, tornando a estimativa mais precisa.

4.2. Pré-processamento: Normalização com MinMaxScaler

Antes de aplicar o KNN, foi necessário normalizar os dados numéricos com “MinMaxScaler”, que transforma todas as colunas para uma mesma escala (entre 0 e 1), pois o KNN utiliza distâncias euclidianas para calcular a proximidade entre registros. Como as colunas estão em escalas diferentes (por exemplo, massa corporal em gramas e comprimento de bico em milímetros), sem a normalização as colunas com valores maiores teriam influência desproporcional.

Após a imputação, aplicamos a desnormalização para retornar os valores à sua unidade original, garantindo que o Data Frame final mantenha os dados com a mesma interpretação que os dados originais.

4.3. Avaliação da Imputação e Distribuição Estatística

Após a imputação, foi realizada uma análise comparativa dos gráficos antes e depois do preenchimento mostra que o KNN conseguiu preservar a forma geral das distribuições.

A representação gráfica das variáveis numéricas por espécie (antes e após a imputação) possibilita a visualização do efeito direto da técnica de preenchimento escolhida. Depois de serem imputadas, as curvas assumiram uma forma mais simétrica, se assemelhando a uma distribuição normal (em forma de sino), o que é visto como ideal em diversas análises estatísticas.

Essa simetria sugere que as informações faltantes foram preenchidas de forma consistente com os padrões já existentes no conjunto, prevenindo distorções. Além disso, a correção dos "bicos" ou distorções perceptíveis antes da imputação, como picos irregulares ou caudas assimétricas, é um sinal positivo, pois evidencia que os valores imputados não criaram agrupamentos artificiais nem outliers.

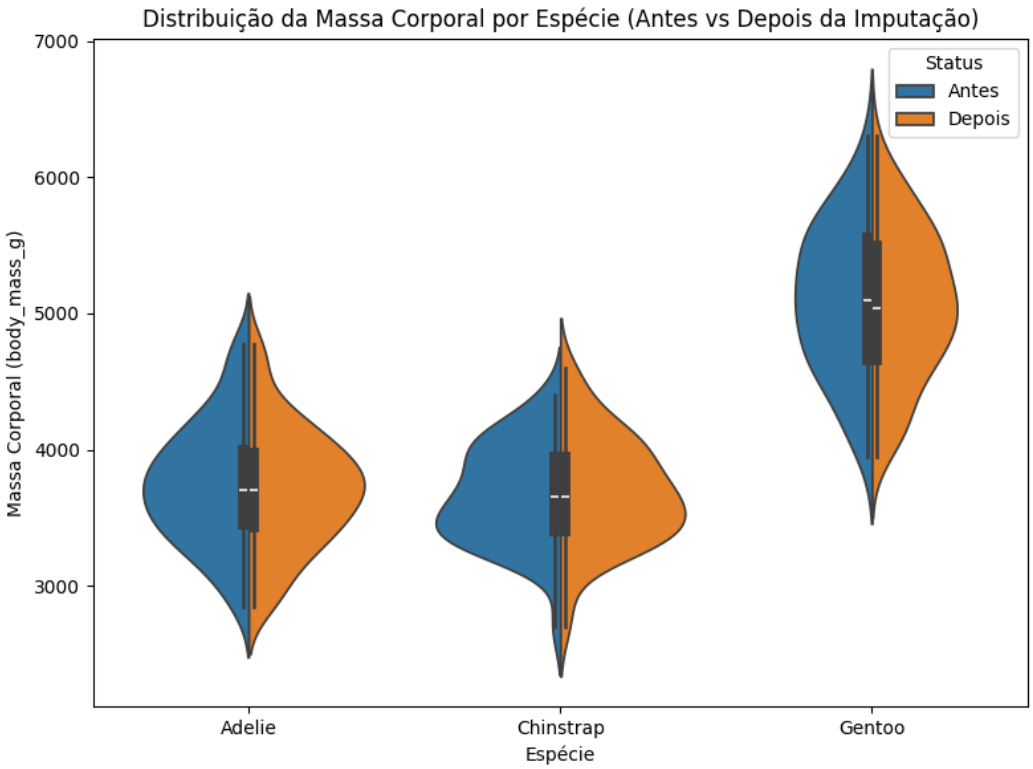

Figura 03 – Gráfico de Distribuição da Massa Corporal por Espécie (Antes vs Depois)

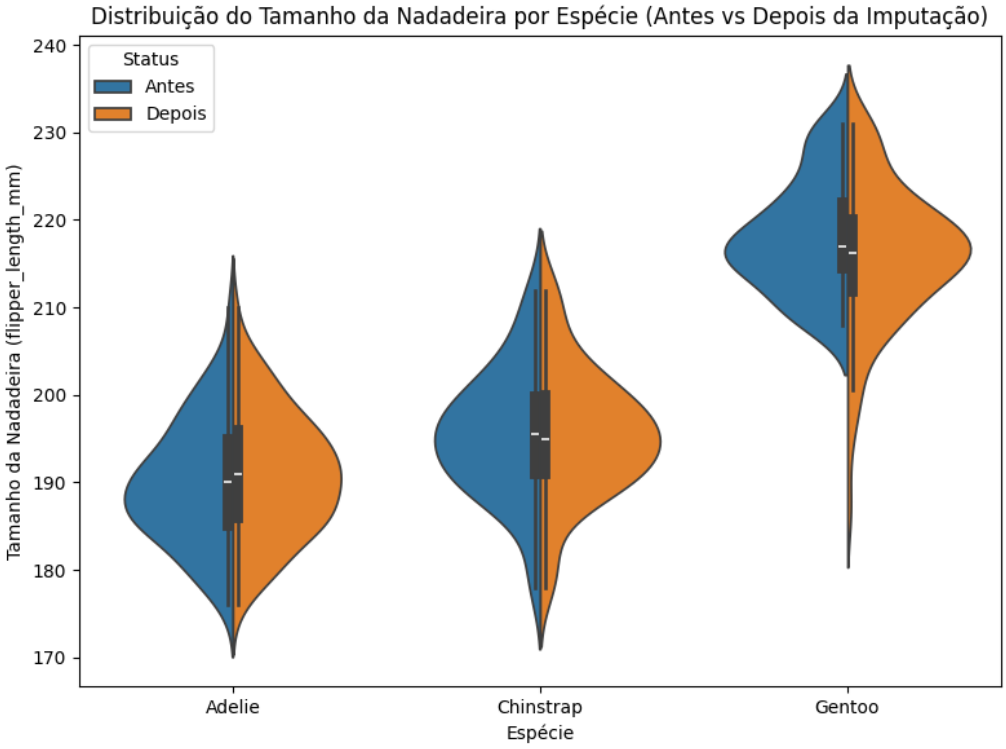

Figura 04 – Gráfico de Distribuição do Tamanho da Nadadeira por Espécie (Antes vs Depois)

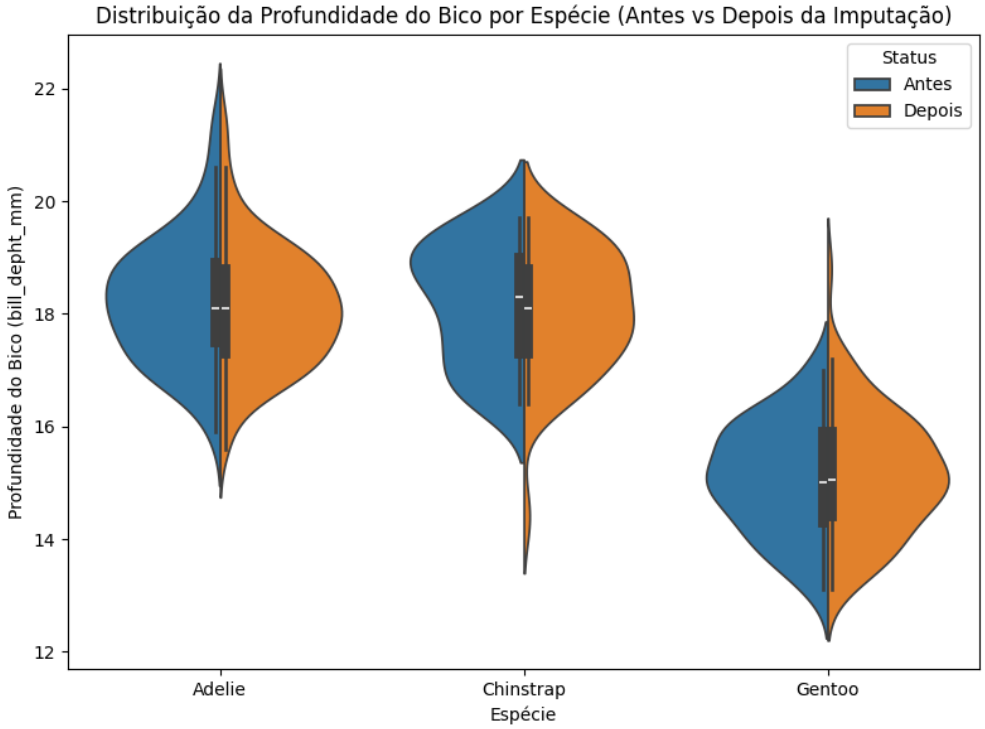

Figura 05 – Gráfico de Distribuição do Tamanho da Nadadeira por Espécie

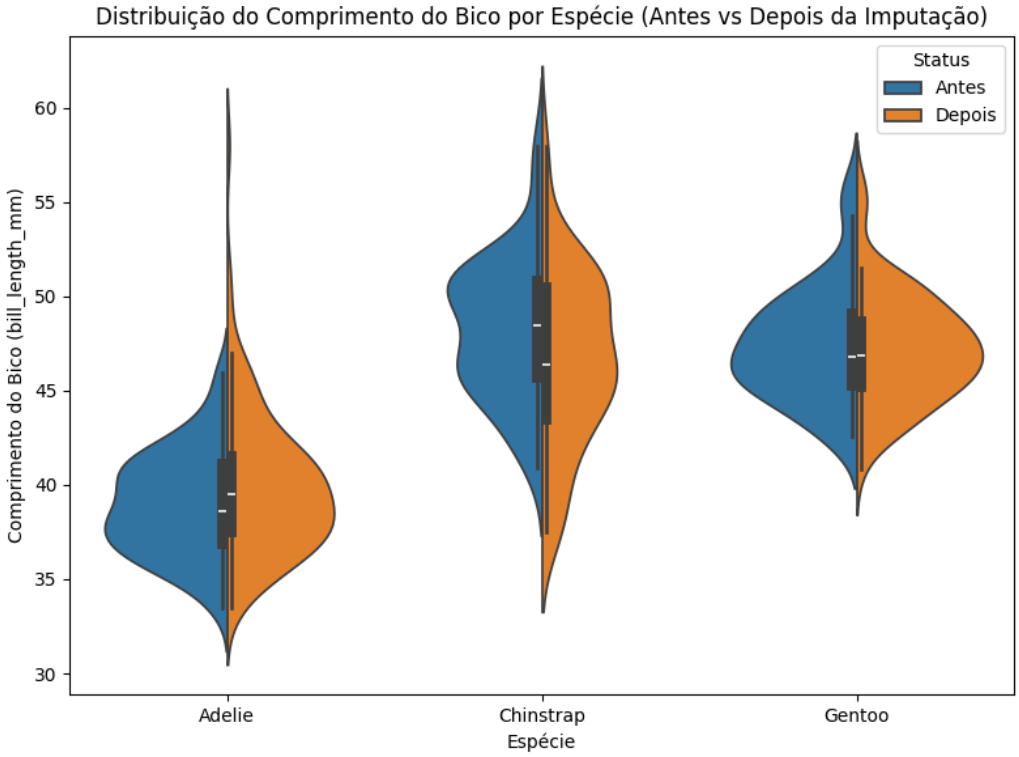

Figura 06 – Gráfico de Distribuição do Comprimento do Bico por Espécie (Antes vs Depois)

4.4. Código de Imputação Utilizado nas Colunas Numéricas

Pseudocódigo 01: Imputação de Colunas Numéricas por KNN

```
#Cópia do DataFrame original com NANs

penguins_numericas = penguinsOriginalNa.copy()


#Normalização

#MinMaxScaler: normaliza os dados para o intervalo [0, 1]

#fit(): calcula os valores mínimos e máximos de cada coluna numérica

scaler = MinMaxScaler()

scaler.fit(penguins_numericas[colunas_numericas])

penguins_norm = scaler.transform(penguins_numericas[colunas_numericas])


#DataFrame normalizado para imputação
```

```
penguins_normDF = pd.DataFrame(penguins_norm, columns=colunas_numericas)


#Ajustando parâmetros

penguins_normDF['species'] = penguins_numericas['species']


#KNN

#KNNImputer: preenche valores ausentes com base nos vizinhos mais
próximos

#n_neighbors=5, decidindo o k

#weights='distance', para dar mais peso para valores mais próximos

#copy = True,para o imputador fazer uma cópia dos dados ao invés de
modificá-los diretamente

#fit(): ajusta o modelo de imputação com os dados normalizados

imputer = KNNImputer(n_neighbors=5, weights='distance', copy=True)

imputer.fit(penguins_normDF[colunas_numericas])


#transform(): realiza a imputação nas colunas numéricas

penguins_normDF[colunas_numericas] =
imputer.transform(penguins_normDF[colunas_numericas])


#Desnormalização

#inverse_transform(): desfaz a normalização, volta para a escala
original

penguins_desnorm =
scaler.inverse_transform(penguins_normDF[colunas_numericas]).round(1)

#DF com valores imputados e reanexando a coluna 'species'

penguins_numimputDF = pd.DataFrame(penguins_desnorm,
columns=colunas_numericas)
```

```
penguins_numimputDF['species'] = penguins_normDF['species']

penguins_numimputDF
```

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	species
0	37.7	18.7	180.0	3750.0	Adelie
1	39.5	17.4	186.0	3636.8	NaN
2	40.3	18.0	195.0	3250.0	Adelie
3	43.7	17.2	200.6	4173.5	Adelie
4	35.0	19.3	193.0	3450.0	Adelie
...	...	...	...	...	...
339	43.7	17.2	200.6	4173.5	Gentoo
340	46.8	14.3	215.0	5000.0	Gentoo
341	50.1	15.3	218.5	5750.0	NaN
342	45.2	14.8	217.0	5200.0	Gentoo
343	50.5	15.9	213.0	5400.0	NaN

344 rows × 5 columns

Figura 07 – DataFrame das Colunas Numéricas Imputadas

5. Imputação de Colunas Categóricas

As colunas categóricas do dataset “species”, “island” e “sex” também são essenciais para analisar os pinguins registrados. Essas variáveis servem como base para análises comparativas entre grupos e influenciam diretamente na interpretação dos dados numéricos. Antes da imputação, é importante entender o que é cada uma:

- **species:** Indica a espécie do pinguim (Adelie, Chinstrap ou Gentoo). Essa informação é central na análise biológica, pois muitas das variáveis variam de acordo com a espécie.
- **island:** Refere-se à ilha de origem do pinguim (Biscoe, Dream ou Torgersen), sendo útil para entender a distribuição geográfica das espécies e possíveis adaptações ambientais.
- **sex:** Indica o sexo do pinguim (Male ou Female), fundamental para entender diferenças físicas entre machos e fêmeas.

Essas colunas também contêm valores que não estão presentes no dataset usado, prejudicando a análise de agrupamentos, a visualização segmentada e a compreensão de padrões entre os grupos.

Para a imputação dos valores ausentes nas colunas categóricas da base Penguins, utilizamos dois métodos distintos, cada um escolhido com base nas características e distribuição dos dados de cada variável.

5.1. Justificativa do Método FFILL – Colunas Species e Island

Para as colunas species e island, optamos pelo método de imputação chamado "Forward Fill (ffill)", que basicamente preenche os valores ausentes com o valor imediatamente anterior da mesma coluna. Escolhemos essa abordagem por perceber que os dados estavam organizados de forma sequencial, com várias linhas seguidas pertencentes a uma mesma espécie de pinguim ou registradas na mesma ilha. Como essas variáveis são categóricas, qualquer tentativa de imputação numérica ou estatística não se aplicaria de forma apropriada. O método ffill respeita a estrutura categórica, mantendo a consistência com o valor anterior observado.

Esse tipo de organização sugere que as informações podem ter sido coletadas em blocos, por exemplo: "vários pinguins da mesma espécie sendo analisados em sequência no mesmo local". Assim, ao usar o valor anterior para preencher os vazios, conseguimos manter uma certa lógica local, o que ajuda a evitar a inserção de dados incoerentes ou aleatórios.

Após a aplicação desse método, fizemos uma contagem das espécies e das ilhas para verificar se os preenchimentos mantiveram o padrão esperado. A espécie Adelie continuou sendo a mais frequente na base, seguida por Gentoo e Chinstrap, o que corresponde ao padrão antes da imputação. O mesmo aconteceu com a coluna island, onde a ilha Biscoe manteve o maior número de registros, seguida por Dream e Torgersen.

Antes

species	count
Adelie	101
Gentoo	82
Chinstrap	49

Depois

species	count
Adelie	154
Gentoo	124
Chinstrap	66

Figura 08 – Antes e Depois das Espécies

Antes

island	count
Biscoe	124
Dream	86
Torgersen	31

Depois

island	count
Biscoe	169
Dream	124
Torgersen	51

Figura 09 – Antes e Depois das Ilhas

5.2. Código de Imputação Utilizado – Species e Island

Pseudocódigo 02: Imputação das Colunas Categóricas Species e Island por FFILL

```
#Copia o DataFrame com apenas as colunas categóricas

penguins_categoricasDF = penguinsOriginalNa[colunas_categoricas].copy()



#Método FFILL

#ffill() = forward fill: preenche valores ausentes com o valor anterior
da mesma coluna

#Se uma célula está vazia, ela receberá o valor da célula de cima

#Utilizada pois os dados seguem uma sequência

penguins_categoricasDF = penguins_categoricasDF.ffill()

#DF do resultado após a imputação

penguins_categoricasDF
```

	species	island
0	Adelie	Torgersen
1	Adelie	Torgersen
2	Adelie	Torgersen
3	Adelie	Torgersen
4	Adelie	Torgersen
...	...	...
339	Gentoo	Biscoe
340	Gentoo	Biscoe
341	Gentoo	Biscoe
342	Gentoo	Biscoe
343	Gentoo	Biscoe

344 rows × 2 columns

Figura 10 – DataFrame com Espécies e Ilhas Imputadas

5.3. Justificativa Método por Característica – Coluna Sex

A coluna sex apresentou uma quantidade significativa de valores ausentes, e por se tratar de uma variável categórica com ligação direta a características físicas, optamos por um método de imputação mais contextualizado: relacionar o sexo do pinguim com a profundidade do bico (bill_depth_mm) dentro de cada espécie.

Em várias espécies de pinguins, machos e fêmeas possuem diferenças sutis, mas perceptíveis, nas medidas corporais. A profundidade do bico é uma dessas medidas que pode ajudar a diferenciar os sexos. Por isso, calculamos a mediana do bill_depth_mm para cada combinação de espécie e sexo (por exemplo: Adelie/Male, Adelie/Female, etc). Com esses dados em mãos, criamos uma lógica que compara o valor do bico do pinguim com as duas medianas da espécie correspondente, e atribuímos o sexo cuja mediana estava mais próxima daquele valor.

Escolhemos usar a mediana (e não a média), porque ela é menos afetada por valores muito altos ou muito baixos, o que deixa a comparação mais confiável. Isso foi importante, porque como são dados de campo, pode ter alguma variação natural ali.

Essa estratégia foi escolhida porque, além de respeitar os padrões naturais dos animais, ela evita distorções que poderiam acontecer com métodos mais simples. Fazer isso poderia gerar um desequilíbrio artificial entre machos e fêmeas no conjunto de dados.

5.4. Código de Imputação Utilizado – Sex

Pseudocódigo 03: Imputação da Coluna Categórica Sex por Característica

```
#Criação de um DataFrame parcial com colunas categóricas (já imputadas)

#e colunas numéricas (já imputadas e desnormalizadas)

#penguins_numimputDF.drop('species', axis=1)], axis=1) -> evitar que
species seja duplicada

#Agregar a coluna 'sex' original (ainda com valores ausentes)

penguins_parcial_imput = pd.concat([

    penguins_categoricasDF,

    penguins_numimputDF.drop('species', axis=1)

], axis=1)

penguins_parcial_imput['sex'] = penguinsOriginalNa['sex']



# Criar uma cópia do DataFrame original

penguins_completo = penguins_parcial_imput.copy()

#Calcular as medianas do bill_depth_mm por espécie e sexo

#groupby(): agrupa os dados pelas colunas 'species' e 'sex'

#median(): calcula a mediana da profundidade do bico ('bill_depth_mm')
para cada grupo

#unstack(): transforma o segundo nível do índice ('sex') em colunas

#Um DF onde cada linha é uma espécie e cada coluna é um sexo ('Male' e
'Female'),

#com os valores sendo a mediana de bill_depth_mm de cada combinação

medianas =penguins_completo.groupby(['species',
'sex'])['bill_depth_mm'].median().unstack()
```

```
#Lista para armazenar os novos valores imputados

valores_imputados = []


#Função para imputar sexo com base na mediana por espécie

#Se o sexo estiver ausente, compara a profundidade do bico com as
medianas

#da espécie para 'Male' e 'Female' e escolhe o mais próximo

def imputar_com_base_na_mediana(row):

    if pd.isna(row['sex']):

        especie = row['species']

        valor = row['bill_depth_mm']


   #Verifica se a espécie existe nas medianas e se o valor não é nulo

        if especie in medianas.index and not pd.isna(valor):

            mediana_m = medianas.loc[especie, 'Male']

            mediana_f = medianas.loc[especie, 'Female']


#Compara a distância entre o valor do bico e as duas medianas

            if abs(valor - mediana_m) < abs(valor - mediana_f):

                valores_imputados.append('Male')

                return 'Male'

            else:

                valores_imputados.append('Female')

                return 'Female'

    return row['sex']  #Se não for nulo, mantém o valor original
```

```
#Aplicar a função

#apply(): aplica a função linha por linha (axis=1)

penguins_completo['sex'] =
penguins_completo.apply(imputar_com_base_na_mediana, axis=1)


penguins_completo
```

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex
0	Adelie	Torgersen	37.7	18.7	180.0	3750.0	Male
1	Adelie	Torgersen	39.5	17.4	186.0	3636.8	Female
2	Adelie	Torgersen	40.3	18.0	195.0	3250.0	Female
3	Adelie	Torgersen	43.7	17.2	200.6	4173.5	Female
4	Adelie	Torgersen	35.0	19.3	193.0	3450.0	Male
...	...	...	...	...	...	...	...
339	Gentoo	Biscoe	43.7	17.2	200.6	4173.5	Male
340	Gentoo	Biscoe	46.8	14.3	215.0	5000.0	Female
341	Gentoo	Biscoe	50.1	15.3	218.5	5750.0	Male
342	Gentoo	Biscoe	45.2	14.8	217.0	5200.0	Female
343	Gentoo	Biscoe	50.5	15.9	213.0	5400.0	Male

344 rows × 7 columns

Figura 11 – DataFrame com Todas as Colunas Imputadas

6. Dashboard com os Dados da Base Imputada

Com base nos dashboards construídos após a imputação dos dados, é possível observar melhorias claras na estrutura e na integridade da base.

6.1. Massa Corporal Média e Tamanho da Asa – Depois

Com a aplicação da imputação de dados, foi possível imputar todos os registros que tinham alguma informação ausente, o que resultou em gráficos mais completos e consistentes. Esse dashboard apresenta a massa corporal média (em gramas) e o tamanho médio da asa (em milímetros), segmentados por ilha, sexo e espécie.

Os dados imputados possibilitam observar com maior precisão que os pinguins Gentoo machos da ilha Biscoe apresentam a maior média de massa corporal entre todos os grupos analisados. Já na ilha Dream, destaca-se a média de peso dos machos da espécie Chinstrap. A

falta de categorias “em branco” ou “desconhecido” indica que os dados foram completados, evitando distorções na análise.

A variável que se refere ao comprimento das nadadeiras também revela padrões mais claros após a imputação. Novamente, os pinguins Gentoo machos da ilha Biscoe apresentam os maiores valores médios. Com os dados preenchidos, agora é possível comparar os grupos com maior confiabilidade, pois não há mais registros incompletos interferindo na visualização.

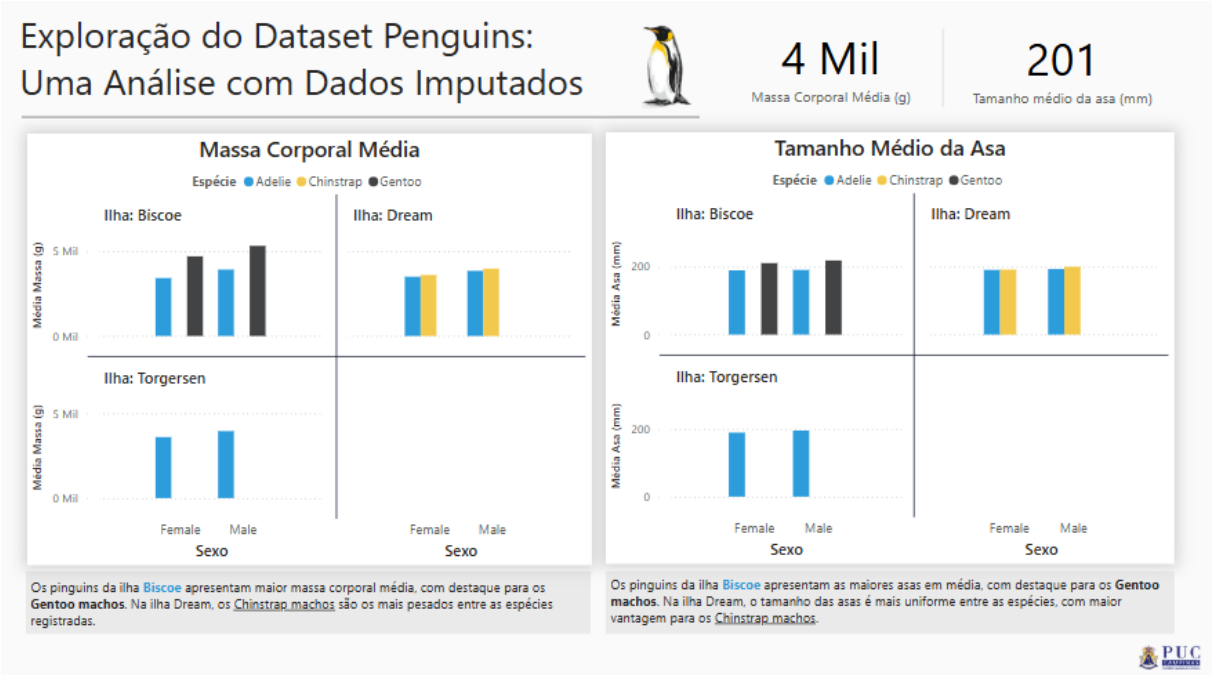

Figura 12 – Dashboard de Massa Corporal Média e Tamanho da Asa Depois da Imputação

6.2. Comprimento e Profundidade do Bico – Depois

Esse dashboard apresenta as médias das variáveis comprimento e profundidade do bico (ambas em milímetros), também organizadas por ilha, sexo e espécie. Com a imputação, os dados foram reconstruídos de maneira coerente com as informações disponíveis, o que se reflete na clareza dos gráficos.

Com a análise completa dos dados, observa-se que os pinguins Gentoo da ilha Biscoe, especialmente os machos, têm os bicos mais longos. Na ilha Dream, são notáveis os machos da espécie Chinstrap. Em relação à profundidade do bico, os pinguins Chinstrap da ilha Dream se destacam, principalmente entre os machos. A uniformidade dos dados possibilita a detecção dessas discrepâncias de maneira mais exata e segura.

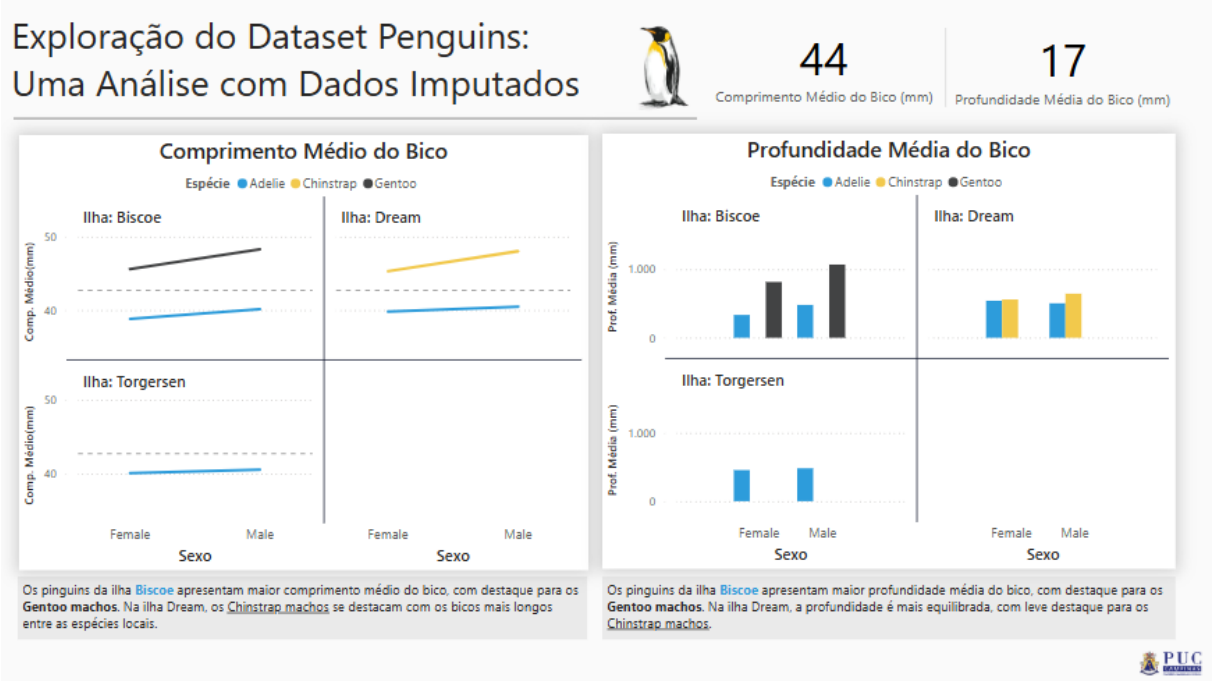

Figura 13 – Comprimento Médio do Bico e Profundidade Média do Bico Antes da Imputação

7. Conclusão

Este trabalho demonstrou, de forma prática e fundamentada, a importância do tratamento adequado de dados em uma base de dados. Com o dataset modificado dos pinguins, foi possível aplicar técnicas de imputação tanto em variáveis numéricas quanto categóricas, com escolhas metodológicas justificadas com base na estrutura e na distribuição dos dados.

A utilização do KNN Imputer, junto com a normalização com MinMaxScaler, permitiu preservar padrões estatísticos relevantes nas variáveis numéricas, enquanto métodos como ffill e imputação por características morfológicas garantiram coerência nas variáveis categóricas. Os dashboards criados após a imputação mostraram resultados mais claros e precisos, facilitando a identificação de padrões por espécie, sexo e ilha. Isso reforça como o tratamento de dados é essencial para garantir análises mais seguras e úteis.